

硬件选型

硬件选型-选型要求

- 低频性能好（放大、不失真）
- 大面积使用，需使用中低价位
- 能耗尽量低
- 收音范围合适
- 在外界复杂环境中使用，必须受温湿度影响尽可能小
- 体积不能特别大
- 产品的质量尽量高、使用寿命尽量长、安装和维修成本低
- 承受声压尽可能大，满足使用需求
- 收录声压较高、脉冲较大的声源必须使用较低灵敏度麦克风

硬件选型-选型原则

- 必要参数是否达标>稳定性>价格>其他性能参数
- 必要参数：最大声压级（AOP）、频率响应、瞬时响应

硬件选型-指标简介

- 分为三类来概述
- 技术指标
- 声学指标
- 市场指标

硬件选型-技术指标

- 灵敏度
- 方向性
- 信噪比 (SNR)
- 最大声压级 (AOP)
- 一致性
- 瞬时响应
- 电源抑制比 (PSRR)
- 频率响应
- 总谐波失真 (THD)
- 阻抗
- 动态范围
- 等效输入噪声 (EIN)

硬件选型-技术指标


- 灵敏度
- 灵敏度是指其输出端对于给定标准声学输入的电气响应。
- 单位声压的输出电压值

$$Sensitivity_{dBV} = 20 \times \log_{10} \left(\frac{Sensitivity_{mV / Pa}}{Output_{REF}} \right)$$

$$Sensitivity_{dBFS} = 20 \times \log_{10} \left(\frac{Sensitivity_{\%FS}}{Output_{REF}} \right)$$

硬件选型-技术指标

- 方向性
- 方向性描述麦克风的灵敏度随声源空间位置的改变而变化的模式。



百家号/博胜TAKSTAR

硬件选型-技术指标

- 信噪比（SNR）表示参考信号与麦克风输出的噪声水平的比值。
- 最大声压级（AOP）指的是麦克风输出THD等于10%时输入的声压大小（SPL）
- 一致性是麦克风在焊接后能否保持原有性能的指标

硬件选型-技术指标

- 瞬时响应即麦克风对瞬态输入的电学反应
- 电源抑制比是麦克风输出对于电源输入噪声抑制能力的参数。
- 频率响应描述麦克风在整个频谱上的输出水平。

硬件选型-技术指标

- 总谐波失真 (THD)
- 阻抗
- 动态范围
- 等效输入噪声 (EIN)

- 声学指标
 - 拾音轴内响应
 - 扩散声场频响
 - 离轴响应
 - 极性响应
 - 通道隔离度
 - 声反馈前增益
 - 离轴声染色
 - 极性图

硬件选型-技术指标

- 市场指标
 - 价格
 - 能耗
 - 稳定性
 - 良品率
 - 使用寿命
 - 供货能力

硬件选型-具体要求

- 技术指标要求
- 枪声在1m处声压级在130-155dB之间，根据声压的距离衰减公式每增加一倍距离衰减6dB，8m处大约在106-131dB，因此对传声器AOP要求至少在135以上
- 枪声爆炸等都是瞬时声波，需要瞬时响应性能好
- 对低频要求敏感，所以选用低灵敏度，大振膜传声器且无变压器输出
- 在300-7000频段范围内频响较好
- 全指向与一致性好

硬件选型-具体要求


- 市场指标要求
- 价格尽量中低、稳定性要求高、能耗尽可能低、使用寿命有保障、供货能力强

硬件选型-种类选型

- 根据声电转换分类
- 电动式（动圈式、铝带式），电容式（ECM、MEMS）、压电式（晶体式、陶瓷式、MEMS）、碳粒式、激光式、光纤式、矢量麦克风


硬件选型-种类选型

- 铝带式
- 优点：音质效果好、双向响应效果好、瞬态响应好
- 致命缺点：价格昂贵且铝片易受损伤、维修成本高、高声压会造成损坏
- 不考虑选用



硬件选型-种类选型

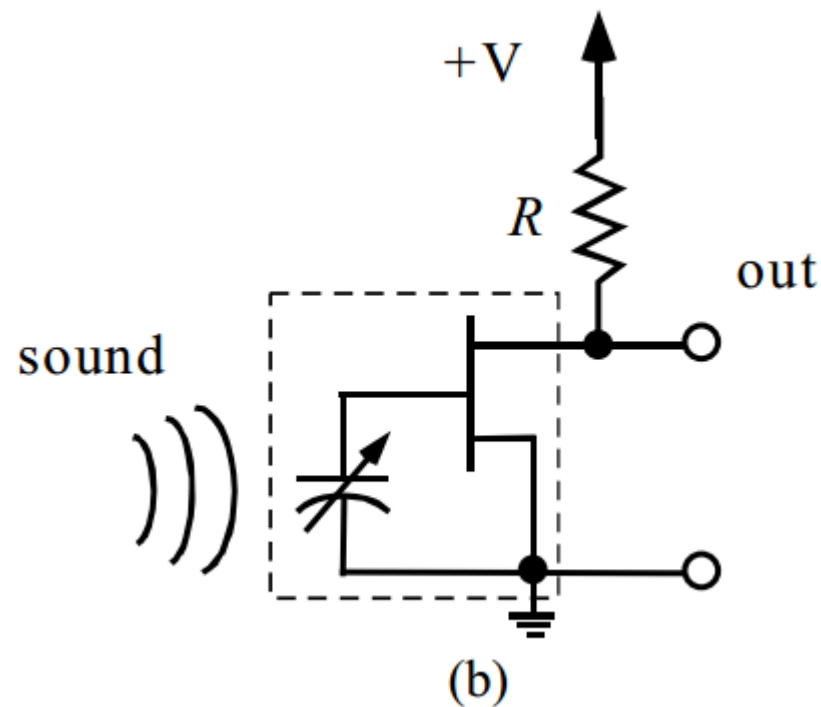

- 动圈式
- 优点：简单坚固、易于小型化、不需要额外供电、不易过载（失真）、指向性好
- 致命缺点：频响和瞬态响应不够好
- 不考虑选用



硬件选型-种类选型


- 电容式
- 优点：频响特性与瞬态响应好
- 缺点：价格较高、需要外部供电、受湿度影响
- 驻极体式（ECM）
- 优点：结构简单，体积小，价格低，瞬态性能好、频响特性好
- 缺点：受湿度影响大、一致性差、内部可能过载（失真）、灵敏度高

硬件选型-种类选型



硬件选型-种类选型

- 压电式
- 优点：输出电平高、价格低
- 缺点：频率响应较差、稳定性差



硬件选型-种类选型

- MEMS式
- 优点：体积小、可SMT、产品稳定性好、不怕温湿度变化、一致性好
- 缺点：价格较高

硬件选型-种类选型

- 最终种类选型：MEMS压电式麦克风
- 优点：
 - 1.信噪比高
 - 2.受湿度、尘土、温度影响小
 - 3.一致性好
 - 4.支持单端与差分输出
 - 5.电源抑制比（PSRR）比传统的高30dB
 - 6.声学过载点（AOP）可以达到150dB的最大声压级
- 缺点：
 - 价格高
 - 瞬时响应与低频频响比驻极体差

硬件选型-产品选型

- Vesper公司的VM2020
- 超高声学过载点 (AOP)
- 差分模拟输出
- 零件间差异小
- 耐用的压电MEMS构造
- 价格2.6美元



硬件选型-产品参数


SPECIFICATIONS

All specifications are at 25°C, VDD = 1.8 V unless otherwise noted

Parameter	Symbol	Conditions	Min.	Typ.	Max.	Units
Acoustic Specifications						
Sensitivity		1 kHz, 94 dB SPL	-66	-63	-60	dBV
Signal-to-Noise Ratio	SNR	94 dB SPL at 1 kHz signal, 20Hz to 20kHz, A-weighted Noise		50		dB(A)
Total Harmonic Distortion	THD	94 dB SPL		0.1		%
Total Harmonic Distortion	THD	149 dB SPL		1		%
Acoustic Overload Point	AOP	10.0% THD		152		dB SPL
Roll Off Frequency		-3dB at 1KHz			80	Hz
Directivity			Omni			
Polarity		Increase in sound pressure	Increase in output voltage			
Electrical Specifications						
Supply Voltage			1.6	1.8	3.6	V
Supply Current		$V_{Supply} \leq 3.6\text{ V}$		248		μA
Power Supply Rejection Ratio	PSRR	VDD = 1.8, 1kHz, 200mV _{pp} Sine wave		90		dB
Power Supply Rejection	PSR	VDD = 1.8, 217Hz, 100mV _{pp} square wave, 20 Hz – 20kHz, A-weighted		-112		dB(A)
Output Impedance	Z _{OUT}			1100		Ω
Output DC Offset		Both Vout+ and Vout-		0.8		V
Startup Time		Within $\pm 0.5\text{dB}$ of actual sensitivity		200		μs

- 灵敏度-63dBV 较低
- 信噪比50dB(A) 较低
- AOP 152dB SPL高
- PSRR 90dB 高
- 响应时间200us 标准
- 阻抗1100 Ω
- 指向性 全指向

硬件选型-产品参数

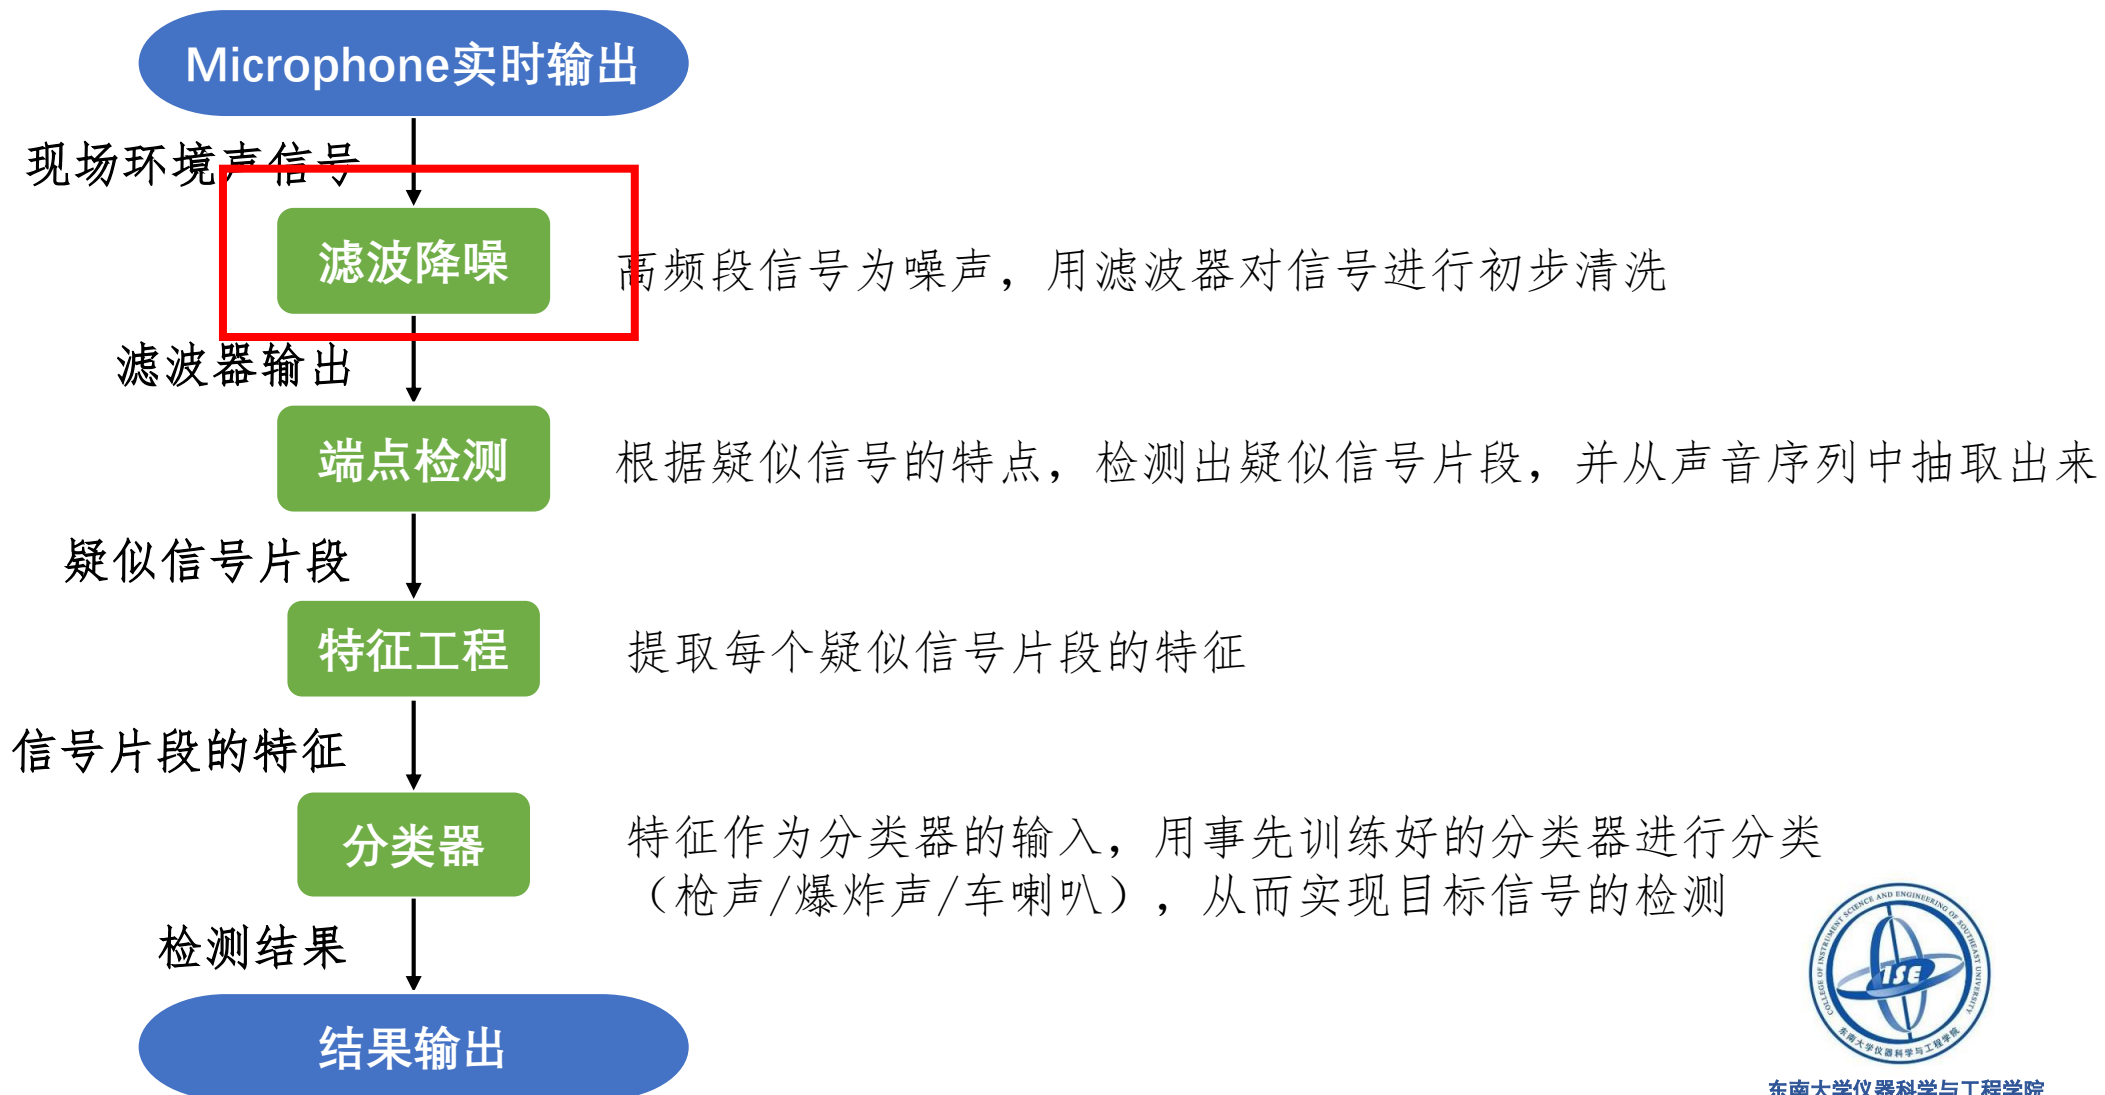


Normalized Frequency Response

软件架构

软件架构

Software Architecture



软件架构 - 滤波降噪

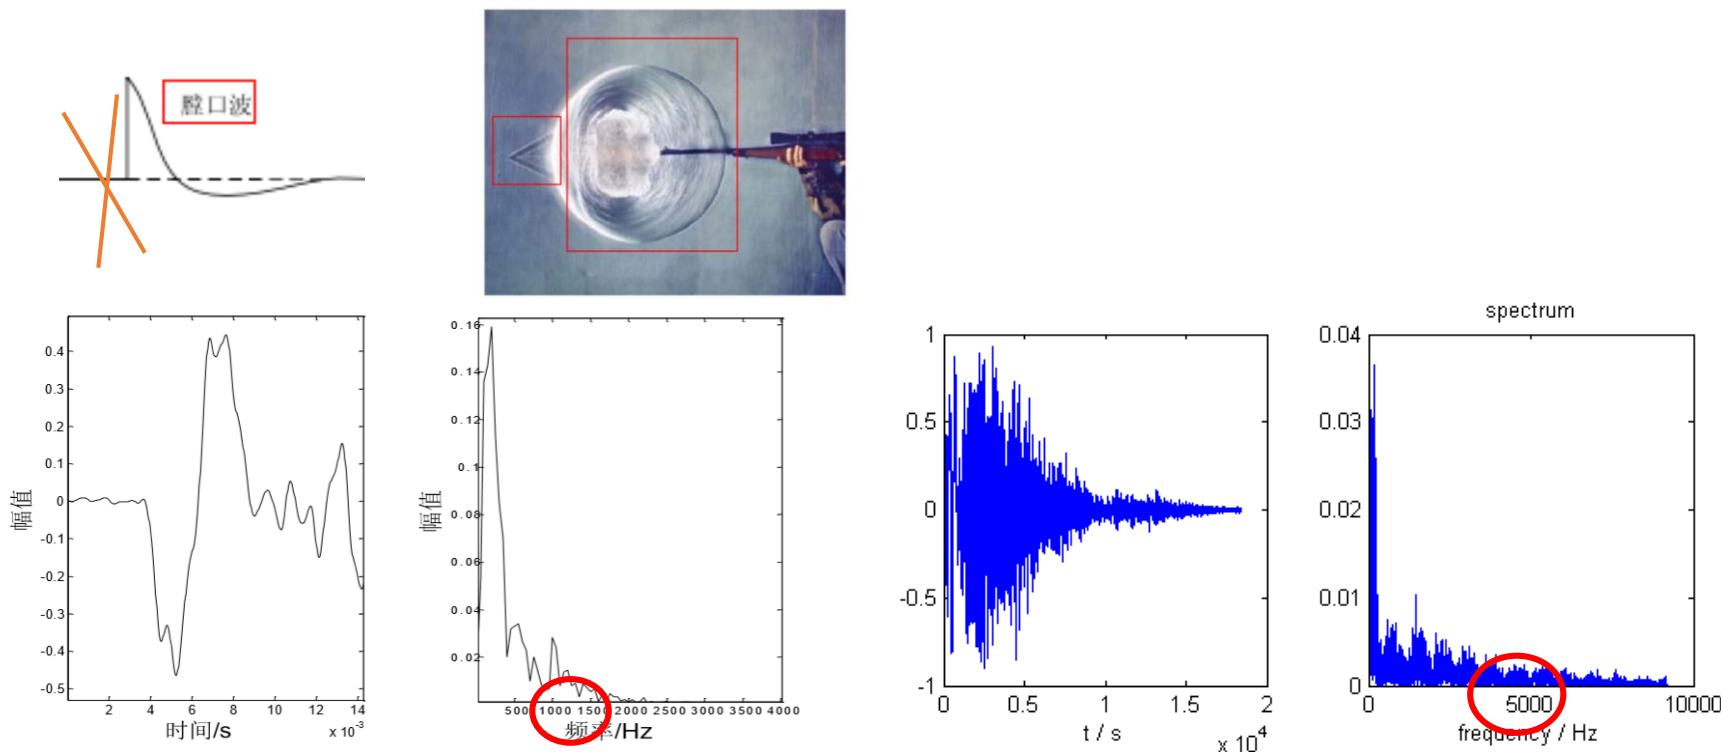
Software Architecture - filtering & denoising

- 为什么要滤波降噪？



先来听一段典型的枪声信号

典型的枪声信号是一个负压-正压的一个过程
理论波形的频率集中在低频【1】 【2】



软件架构 - 滤波降噪

Software Architecture - filtering & denoising




滤波降噪方案

Butterworth Filter实现低通滤波(cutoff frequency = 1kHz)

考虑使用更好的滤波方案？直接把枪声波形过滤出来后进行**相关分析(correlation)**？

均值滤波(order $\geq 1k$)、谱减法【1】等方法的确有可行性，但仿真中出现了各种各样的波形……

另外：这势必无法解决其他低频信号的干扰，比如汽车喇叭！



软件架构 - 滤波降噪

Software Architecture - filtering & denoising


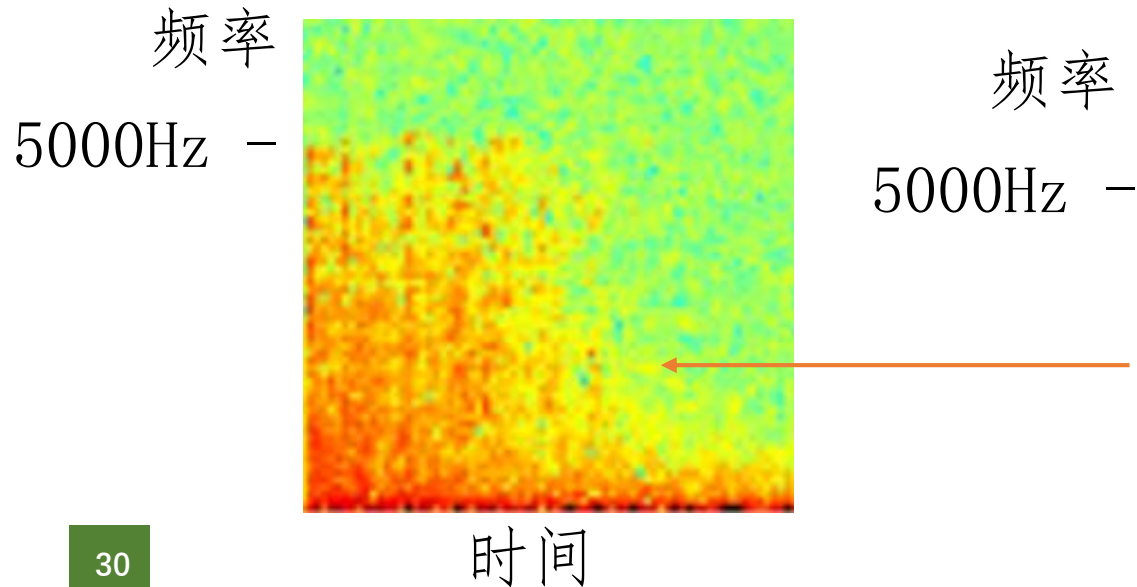
- 滤波降噪方案

Butterworth Filter实现低通滤波(cutoff frequency = 1kHz)

- 考虑使用更好的滤波方案？直接把枪声波形过滤出来后进行**相关分析(correlation)**？

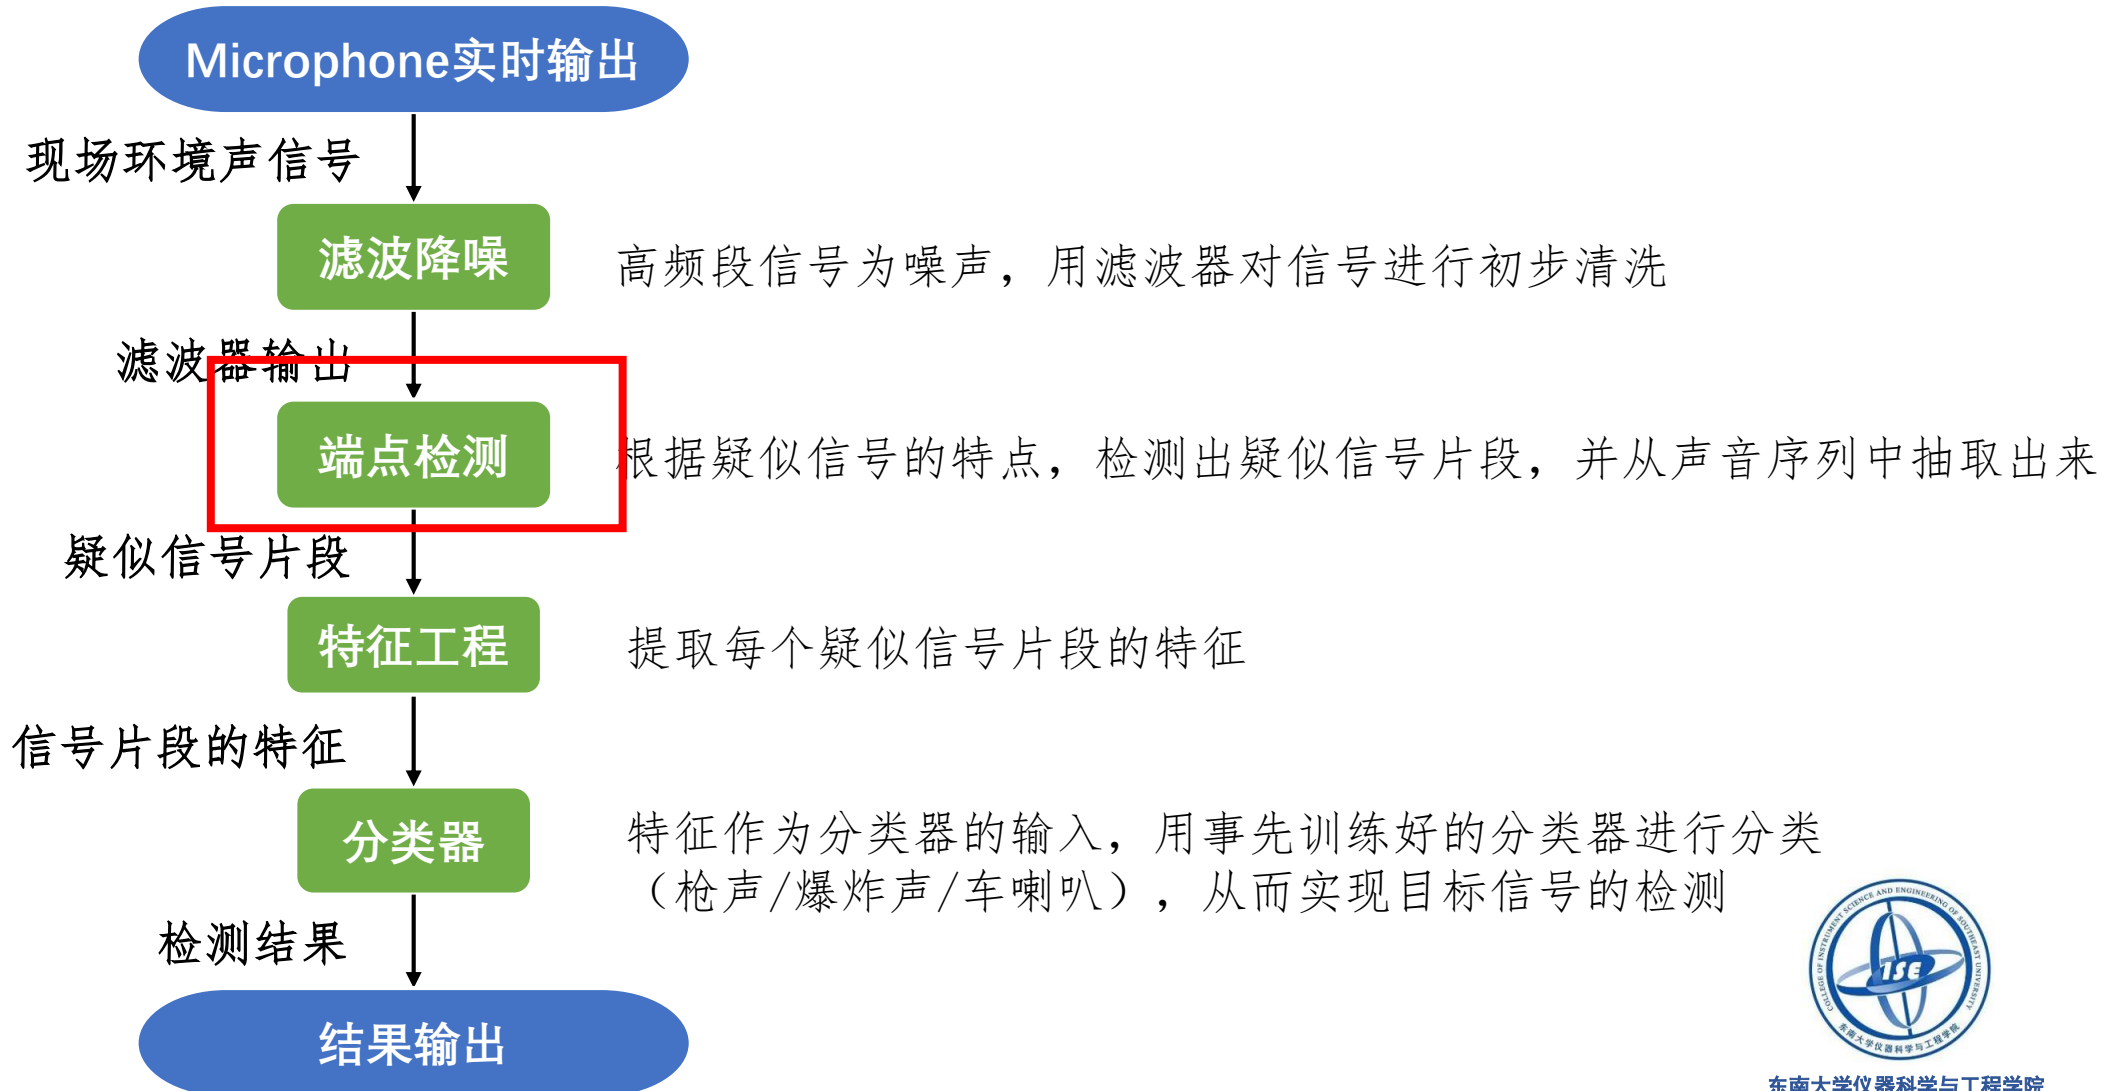
均值滤波(order $\geq 1k$)、**谱减法【1】**等方法的确有可行性，但仿真中出现了各种各样的波形……

另外：（均值滤波）势必无法解决其他低频信号的干扰，比如汽车喇叭！



软件架构

Software Architecture



软件架构 – 端点检测

Software Architecture – endpoint detection

- 端点检测 (Endpoint Detection): 从一端语音信号中准确的找出语音信号的起始点和结束点 【3】
- 为什么要端点检测?

端点检测最早出现在语音信号处理的研究里，用于对话音片段进行精确分割，从而为后续的语音识别等语音信号处理做准备。

声信号识别，或者说声学事件检测，跟语音识别有异曲同工的地方，语音识别将语音信号按语音片段进行分割，从而对每个片段分别做识别；声学事件检测同样需要先把可疑的声学信号片段分割出来，然后再进一步对每个可疑片段进行检测 【8】

语音识别：怎么找到人声的开始点和结束点？

声学事件检测：怎么找到声学事件（枪声/爆炸声/喇叭声）的开始点和结束点？

软件架构 – 端点检测

Software Architecture – endpoint detection

- 常用方法【3】：
操作最简单：基于短时能量(short-time energy)、基于短时过零率(short-time ZCR)
其他方法：双门限法、自相关法、谱熵法、比例法、对数频谱距离法……

- 基于短时过零率(short-time ZCR)

定义语音信号 $x_n(m)$ 的短时过零率 Z_n 为

$$Z_n = \frac{1}{2} \sum_{m=0}^{N-1} | \text{sgn}[x_n(m)] - \text{sgn}[x_n(m-1)] |$$

- 基于短时能量(short-time energy)【4】

设第 n 帧语音信号 $x_n(m)$ 的短时能量用 E_n 表示，则其计算公式如下：

$$E_n = \sum_{m=0}^{N-1} x_n^2(m)$$

- 综合应用场景（枪声/爆炸/喇叭都是大功率信号）、算法复杂度（可高度并行化）、仿真结果等，采用基于短时能量的端点检测




【3】语音信号处理，机械工业出版社，赵力等

【4】基于短时能量和小波去噪的枪声信号检测方法，电测与仪表，张克刚等

软件架构 – 端点检测

Software Architecture – endpoint detection

- **分帧(frame)**: 平稳信号处理方法不能应用于非平稳过程, 但如果非平稳信号在一个短时间范围内, 其特性基本保持不变, 那么可以视作具有**短时平稳性**。**分帧**就是将非平稳信号碎片化为一个个近似平稳的短时信号的操作。
- 声学信号处理的许多运算和特征分析都是基于帧的!



设第 n 帧语音信号 $x_n(m)$ 的短时能量用 E_n 表示, 则其计算公式如下:

$$E_n = \sum_{m=0}^{N-1} x_n^2(m)$$


- 为了保证帧的连续性, 分帧往往会重叠, 重叠部分利用**加窗 (windowing)**弱化其影响

软件架构 – 端点检测

Software Architecture – endpoint detection

- 加窗(windowing): 常用窗口有矩形窗、Hamming窗、汉宁窗等
- Hamming窗【3】: 声学检测、语音处理等研究中非常常用

$$h(n) = \begin{cases} 0.54 - 0.46\cos[2\pi n/(N-1)], & 0 \leq n \leq N-1 \\ 0, & n = \text{其他} \end{cases}$$



软件架构 – 端点检测

Software Architecture – endpoint detection

实时声信号

分帧


加窗

短时能量计算

均值滤波

持续时间滤波


前景背景分割



- 前景 VS 背景
将短时能量作为前景和背景的区别依据，使用自适应的短时能量阈值【4】，实现背景片段和可疑片段（前景）的分离


$$THr = \min(En) + 0.2[\max(En) - \min(En)]$$

仿真结果发现系数取0.4准确率更高



- 均值滤波(mean filtering)

部分仿真结果中出现一定的高频抖动，考虑使用均值滤波做一个平滑。能够有效防止前景片段明明还没结束，但中间一两个点因抖动掉到阈值以下影响分离



软件架构 – 端点检测

Software Architecture – endpoint detection

实时声信号

分帧



加窗

短时能量计算

均值滤波


持续时间滤波

前景背景分割



- 持续时间滤波(duration filtering)

一个突发声信号通过前文的短时能量自适应阈值分割, 从背景中分离出来后, 常常伴随一系列次要片段(可以是回响、多径等原因引起)。次要片段高度碎片化, 持续时间短, 难以提取有效的特征进行检测, 用持续时间作为阈值滤去



软件架构 – 端点检测

Software Architecture – endpoint detection

实时声信号

分帧
















加窗

短时能量计算

均值滤波

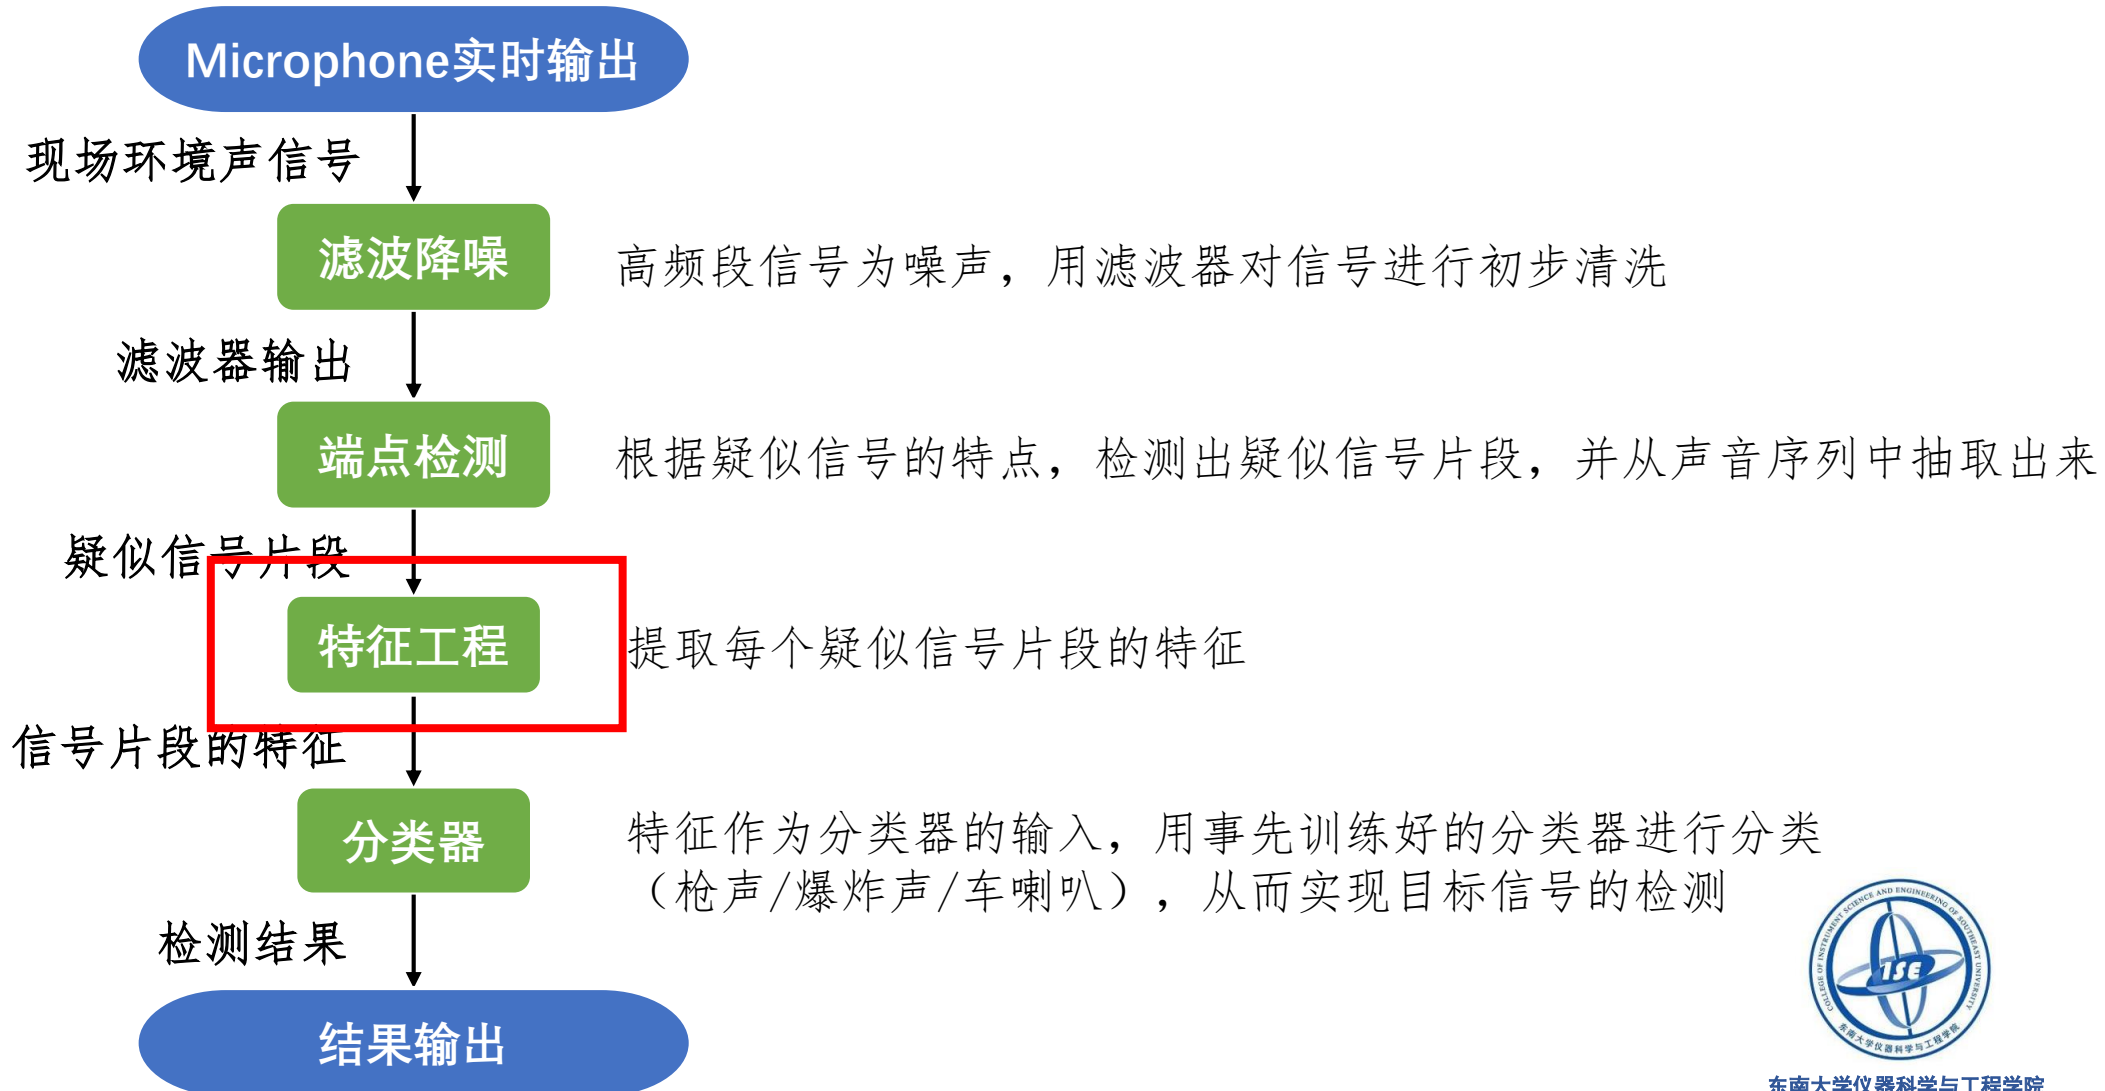
持续时间滤波

前景背景分割



软件架构

Software Architecture



软件架构 – 特征工程

Software Architecture – feature engineering

- 为什么需要特征？


一个孤立、短促的枪声采样点高达 $6w+$ 个 \rightarrow 信号长度为 $6w+$ （单声道）。端点检测分离出主要片段后呢？仍有 $2w+$

必须要提取特征作为输入（维数大大减少），分类器的使用才存在可能！

试图做一个 $2w+$ 维度输入的分类器不可行、不现实（点之间的距离范数过大，不利于聚类）

- Mel频率倒谱系数MFCC (Mel-Frequency Cepstral Coefficient) 【3】

仿照人耳：设置一个滤波器组，1个输入信号， L 个并行滤波器 (Mel滤波器) \rightarrow L 个滤波器输出用 L 个输出构造 L 维向量作为声音片段的特征



软件架构 – 特征工程

Software Architecture – feature engineering

疑似信号片段


Mel频率转换

滤波器组滤波


对数处理

余弦变换

MFCC特征(向量)




汽车喇叭



Mel滤波器组输出

枪声MFCC分析



$$\text{Mel}(f) = 2595 \lg(1 + f/700)$$

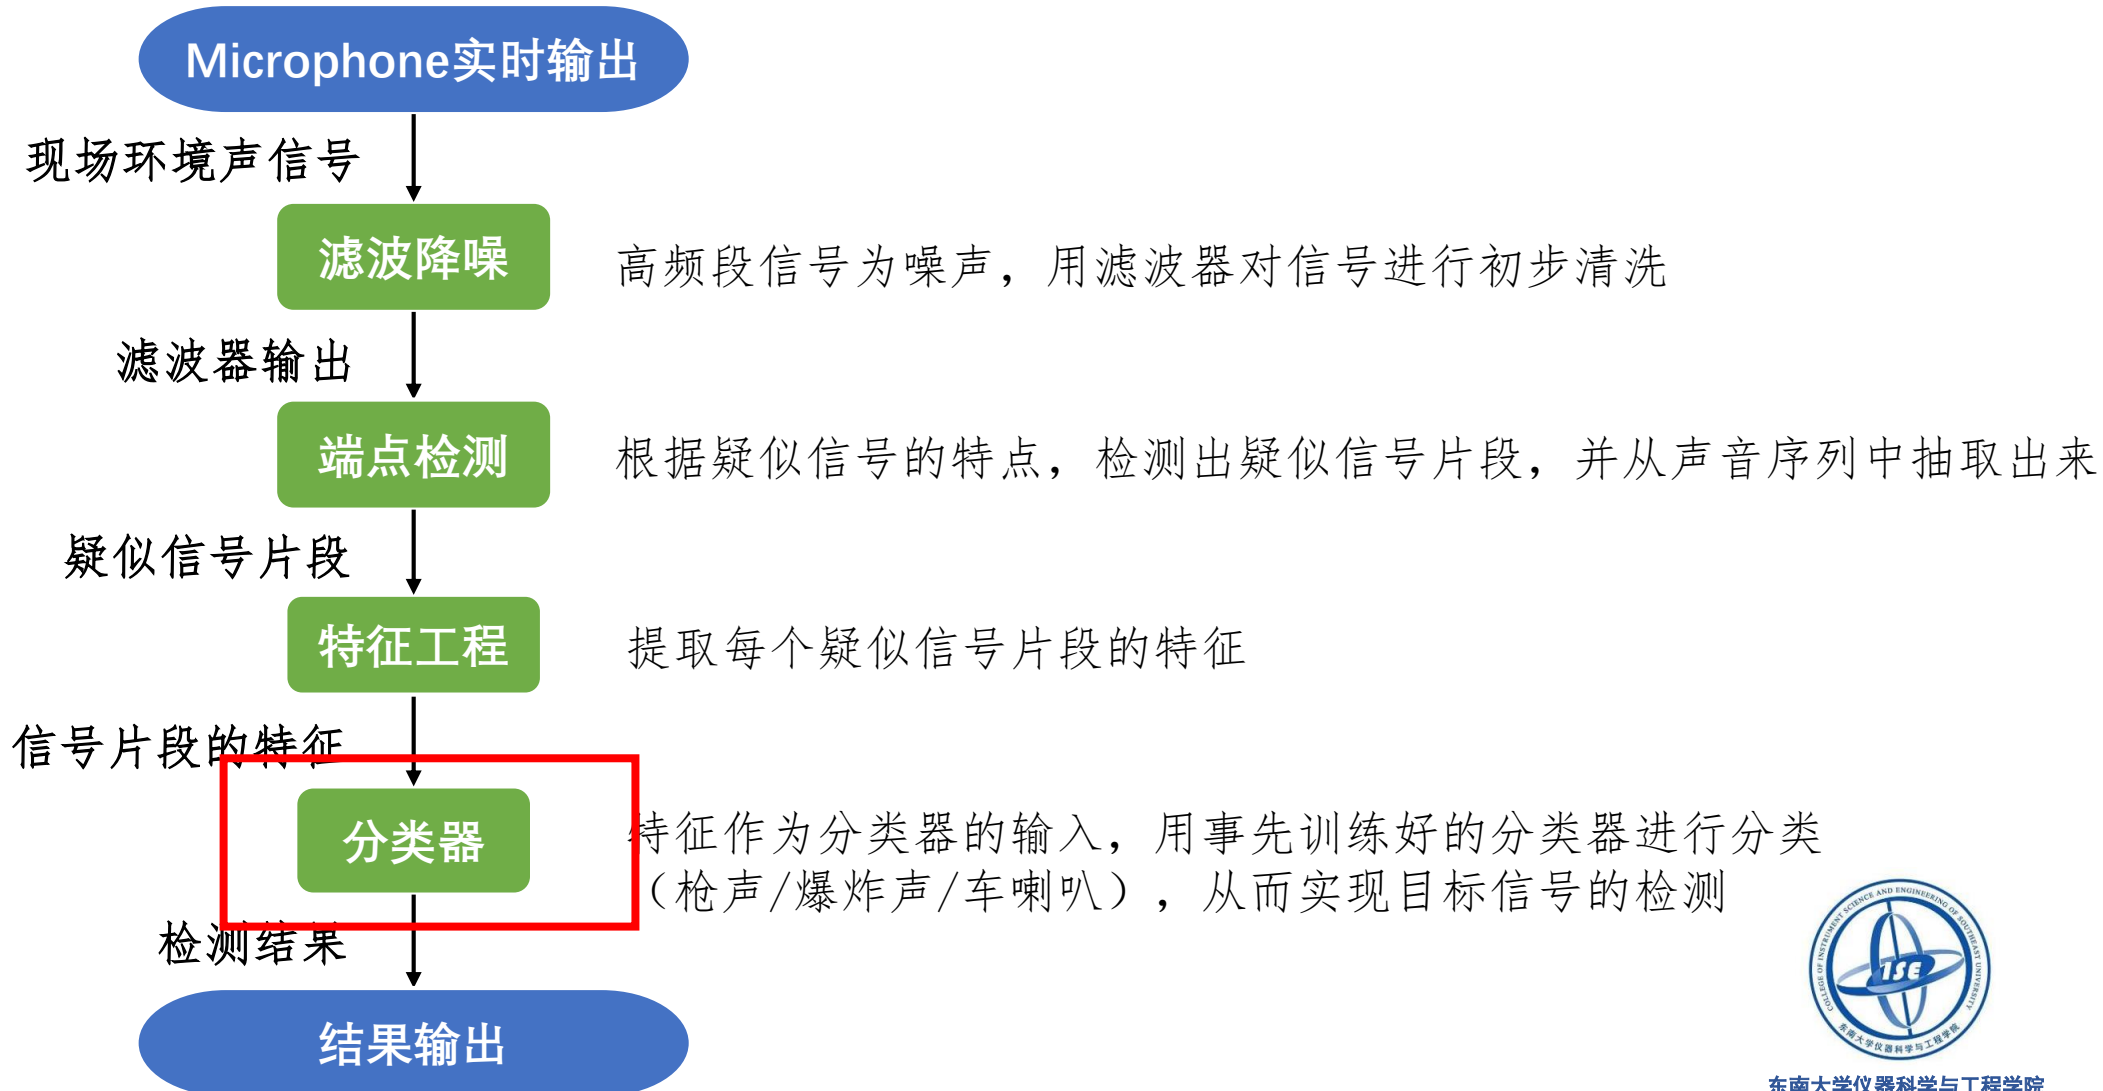
$$m(l) = \sum_{k=o(l)}^{h(l)} W_l(k) |X_n(k)| \quad l = 1, 2, \dots, L$$

$$W_l(k) = \begin{cases} \frac{k - o(l)}{c(l) - o(l)} & o(l) \leq k \leq c(l) \\ \frac{h(l) - k}{h(l) - c(l)} & c(l) \leq k \leq h(l) \end{cases}$$

$$c_{\text{mfcc}}(i) = \sqrt{\frac{2}{N}} \sum_{l=1}^L \lg m(l) \cos\left\{\left(l - \frac{1}{2}\right) \frac{i\pi}{L}\right\}$$

软件架构

Software Architecture



软件架构 – 分类器

Software Architecture – classifier

- 关于**分类器(classifier)**

时下非常非常非常火爆的研究热点，机器学习(Machine Learning)中的一大研究内容，经典的分类器利用概率统计、统计信号处理、贝叶斯估计等理论，在向量空间中，将特征化的输入进行划分，分类器的一些经典模型【5】：


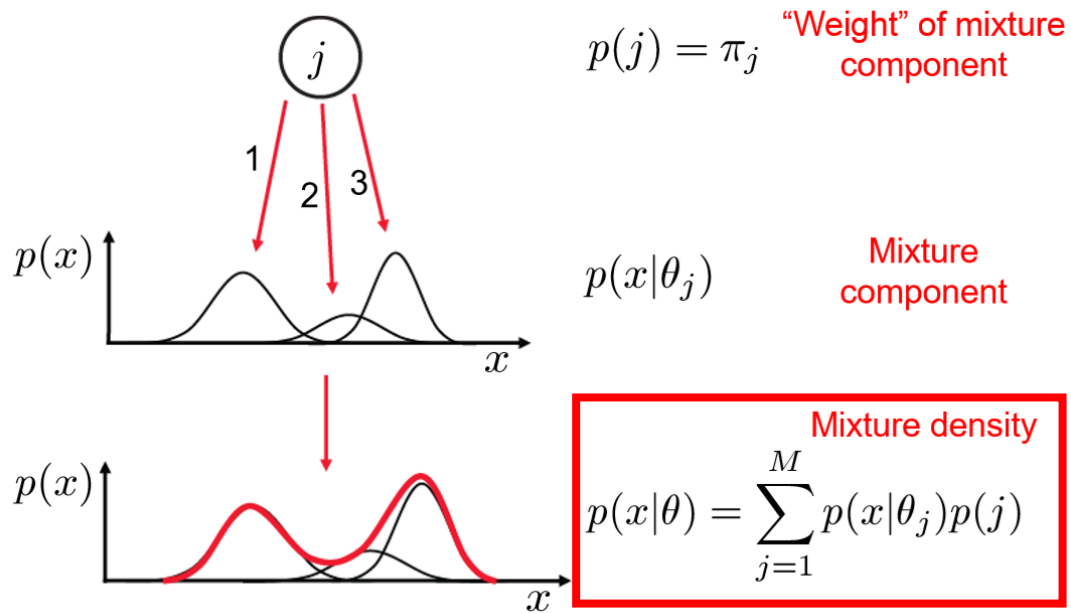
- Bayes决策：需要posterior或者prior & likelihood，需要loss matrix
- 支持向量机SVM(Support Vector Machine)：根据线性可分性分为linear SVM和nonlinear SVM
nonlinear SVM中kernel function的选用比较考究，有一整套理论【6】【7】。~~水太深了.....~~
- Adaboost(Adaptive Boosting)：sensitive to outliers，母前手头的样本太少
- 随机森林(Random Forest)：训练有点复杂
- GMM + Maximum Likelihood Estimation：本项目中使用

软件架构 – 分类器

Software Architecture – classifier


- 混合高斯模型GMM(Gaussian Mixture Model) 【5】 【10】：又叫MoG(Mixture of Gaussian)

“Generative model”



A single parametric distribution is often not sufficient


➤ E.g. for multimodal data



软件架构 – 分类器

Software Architecture – classifier

Step 1: Initialization (eg. K-Means)



Expectation-Maximization (EM) Algorithm

- **E-Step:** softly assign samples to mixture components

$$\gamma_j(\mathbf{x}_n) \leftarrow \frac{\pi_j \mathcal{N}(\mathbf{x}_n | \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)}{\sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x}_n | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)} \quad \forall j = 1, \dots, K, \quad n = 1, \dots, N$$

- **M-Step:** re-estimate the parameters (separately for each mixture component) based on the soft assignments

$$\hat{N}_j \leftarrow \sum_{n=1}^N \gamma_j(\mathbf{x}_n) = \text{soft number of samples labeled } j$$

$$\hat{\pi}_j^{\text{new}} \leftarrow \frac{\hat{N}_j}{N}$$

$$\hat{\boldsymbol{\mu}}_j^{\text{new}} \leftarrow \frac{1}{\hat{N}_j} \sum_{n=1}^N \gamma_j(\mathbf{x}_n) \mathbf{x}_n$$

$$\hat{\boldsymbol{\Sigma}}_j^{\text{new}} \leftarrow \frac{1}{\hat{N}_j} \sum_{n=1}^N \gamma_j(\mathbf{x}_n) (\mathbf{x}_n - \hat{\boldsymbol{\mu}}_j^{\text{new}})(\mathbf{x}_n - \hat{\boldsymbol{\mu}}_j^{\text{new}})^T$$




Step 2 EM Algorithm

软件架构 – 分类器

Software Architecture – classifier

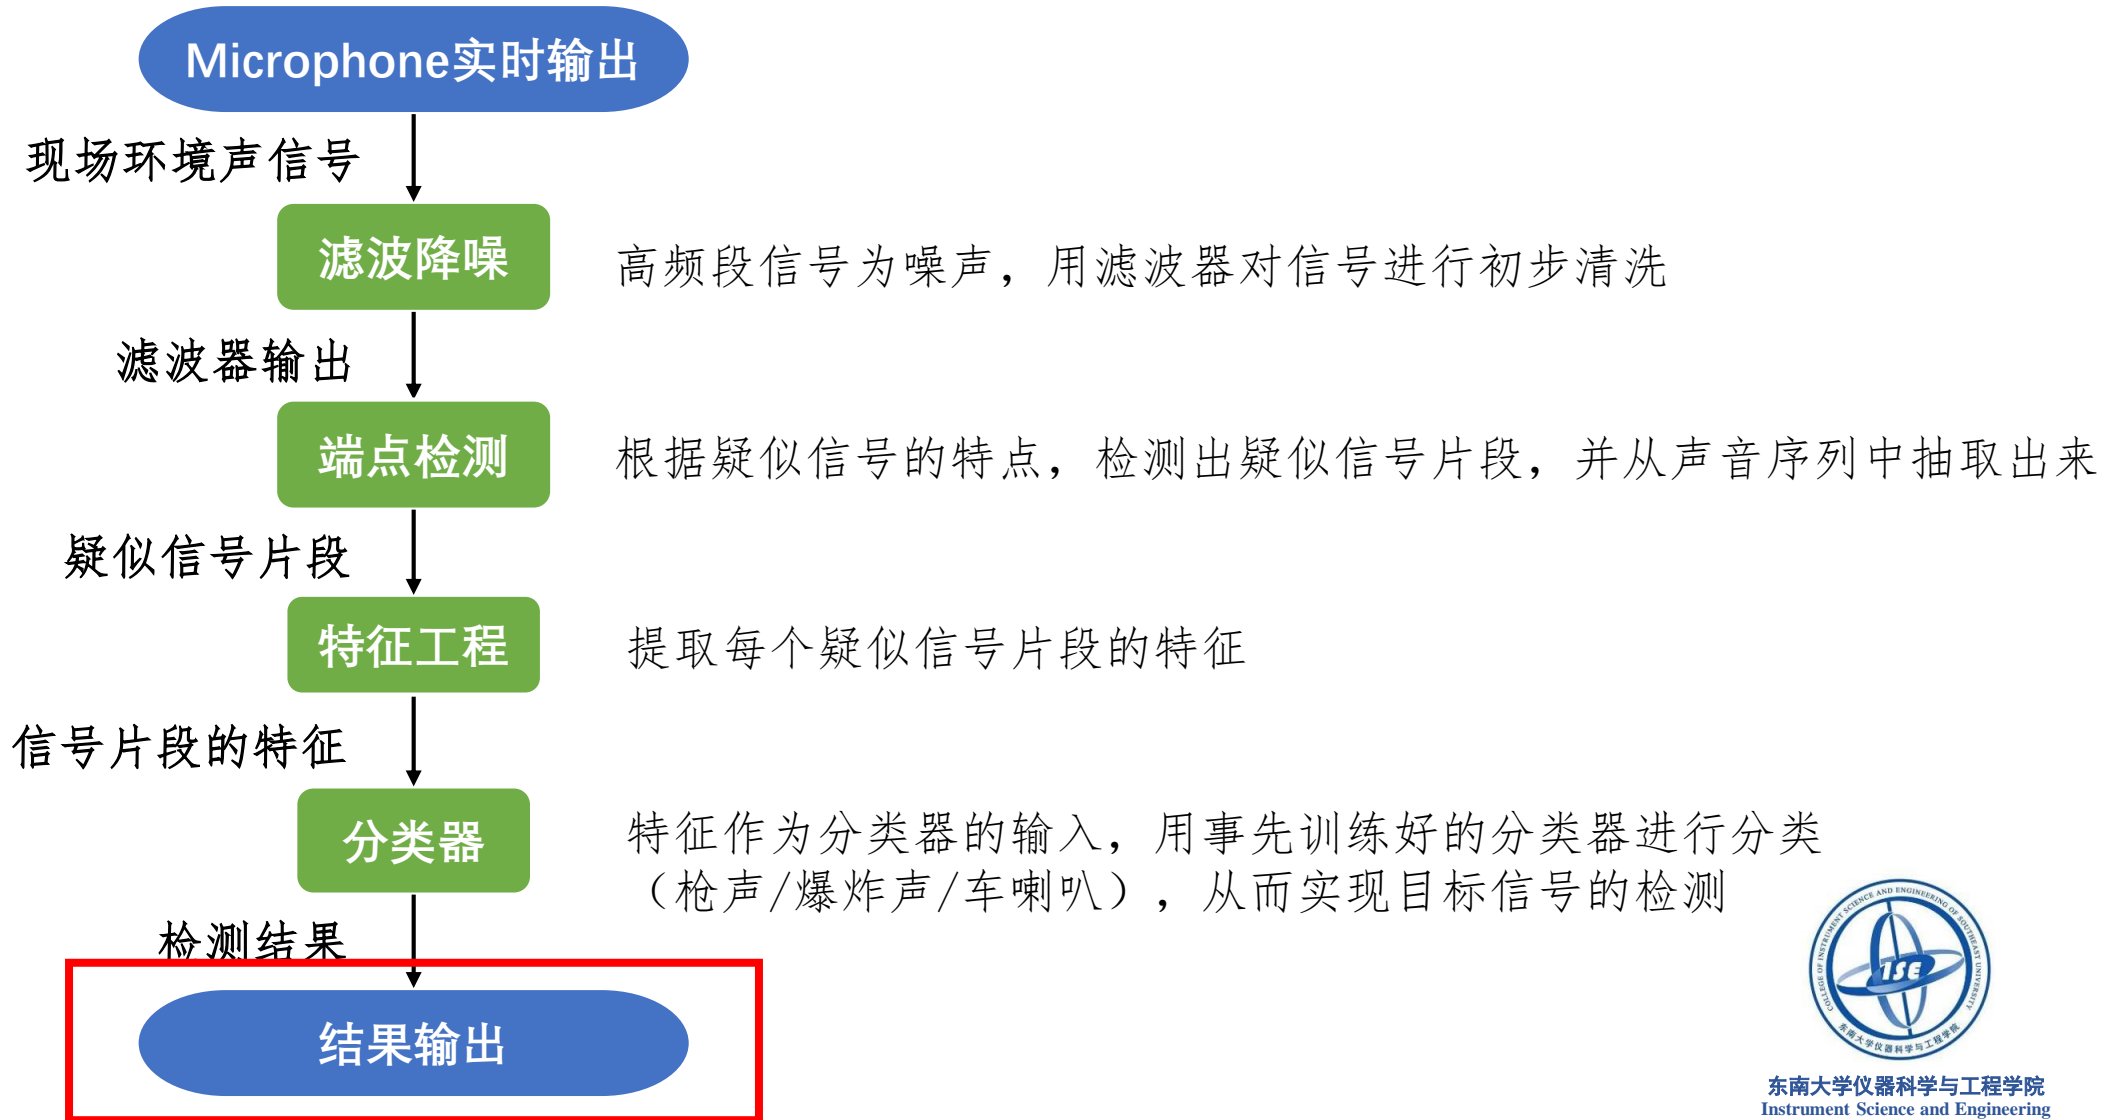
- 极大似然估计ML (Maximum Likelihood Estimation) 【5】 【9】 【10】 【11】 : 对3种声学事件（枪声/爆炸/汽车喇叭）分别训练GMM，得到三个GMM模型。将待检测结果的MFCC特征 \mathbf{x} 分别输入3个GMM，得到3个概率密度，概率密度最大者即认为是该类别

We want to obtain $\hat{\theta}$ such that $L(\hat{\theta})$ is maximized.



软件架构

Software Architecture



参考文献

Reference

